



Gustavo Teodoro Bauke

Interface Web para Regressão Simbólica

Santo André - SP

2025

Gustavo Teodoro Bauke

Interface Web para Regressão Simbólica

Universidade Federal do ABC
Curso de Ciência da Computação

Orientador: Prof. Dr. Fabrício Olivetti de França

Santo André - SP

2025

Dedicatória...

AGRADECIMENTOS

Agradecimentos...

Frase bonitinha sobre computação

RESUMO

RESUMO

Palavras-chave: Regressão Simbólica. Regressão. Aprendizado de Máquina. Interface Web.

ABSTRACT

ABSTRACT

Keywords: Symbolic Regression. Regression. Machine Learning. Web Interface.

SUMÁRIO

	Lista de ilustrações	8
1	INTRODUÇÃO	9
1.1	Contextualização	9
1.2	Objetivos	9
1.3	Justificativa	9
2	REVISÃO DA LITERATURA	11
2.1	Algoritmos de Regressão	11
2.2	Algoritmos Genéticos	11
2.3	Regressão Simbólica	11
2.3.1	Programação Genética para Regressão Simbólica	11
2.4	Saturação de igualdade para Regressão Simbólica	14
2.4.1	Grafos de Igualdade	14
	Referências	16

LISTA DE ILUSTRAÇÕES

Figura 1 – Exemplo de uma árvore de sintaxe abstrata (AST) para a expressão $\log(x/2) + 3x$	12
Figura 2 – Exemplo de cruzamento entre duas expressões representadas por árvores de sintaxe abstrata (ASTs).	13
Figura 3 – Exemplo de mutação em uma expressão representada por uma árvore de sintaxe abstrata (AST).	13
Figura 4 – Exemplo de um grafo de igualdade, adaptado de (Franca; Kronberger, 2025a).	15

1 INTRODUÇÃO

1.1 CONTEXTUALIZAÇÃO

Com evoluções tecnológicas constantes, o uso de técnicas de inteligência artificial (IA), principalmente algoritmos de aprendizado de máquina (AM), tem se tornado cada vez mais comum em diversas áreas. Atualmente, as principais técnicas de IA utilizadas são baseadas em redes neurais e transformadores, que são capazes de aprender padrões complexos a partir de grandes volumes de dados. No entanto, essas técnicas muitas vezes resultam em modelos que são considerados "caixas-pretas", ou seja, cuja lógica interna é difícil de interpretar e compreender totalmente. Em algumas áreas, como na medicina, a interpretabilidade dos modelos é crucial, pois permite um entendimento mais profundo dos fenômenos capturados pelos dados.

Dessa forma, outras técnicas de IA, como a regressão simbólica, tem ganhado destaque como forma de obter modelos mais interpretáveis. A regressão simbólica é uma técnica que busca encontrar expressões matemáticas que melhor se ajustam aos dados observados e que respeitem um conjunto pré-determinado de operações matemáticas. Algoritmos de regressão simbólica são capazes de gerar modelos matemáticos que podem ser facilmente interpretados e analisados, o que os torna uma alternativa interessante para aplicações onde a transparência é importante. Várias técnicas podem ser utilizadas para implementar a regressão simbólica, incluindo algoritmos evolutivos ou técnicas híbridas que combinam redes neurais com algoritmos evolutivos.

1.2 OBJETIVOS

O objetivo deste trabalho é fazer uma revisão da literatura sobre regressão simbólica, apresentando suas principais características, técnicas e aplicações. Além disso, será desenvolvida uma interface web para facilitar a exploração de algoritmos de regressão simbólica, permitindo que usuários possam experimentar com diferentes conjuntos de dados e parâmetros do algoritmo.

1.3 JUSTIFICATIVA

Atualmente, ferramentas como TuringBot e HeuristicLab podem ser utilizadas para criação de modelos de regressão simbólica. No entanto, essas ferramentas possuem funcionalidades limitadas e devem ser executadas localmente, o que pode dificultar o

uso em computadores com recursos limitados. A interface web proposta neste trabalho visa superar essas limitações, oferecendo uma plataforma acessível, na qual o treinamento dos modelos é feito remotamente, permitindo que usuários possam explorar a regressão simbólica de forma mais intuitiva e acessível.

Além disso, essa plataforma permitirá que usuários explorem soluções por meio de uma linguagem de consulta, similar ao SQL, para selecionar padrões matemáticos de interesse dentro do espaço de soluções proposto pelo algoritmo, garantindo que conhecimentos prévios sobre os fenômenos estudados possam ser incorporados ao processo de modelagem.

2 REVISÃO DA LITERATURA

2.1 ALGORITMOS DE REGRESSÃO

Regressão é o processo de descobrir relações entre variáveis de entrada e de saída a partir de um conjunto de dados (Stulp; Sigaud, 2015). As técnicas de regressão podem ser divididas em duas categorias principais: regressão paramétrica e não paramétrica.

A regressão paramétrica fixa uma relação funcional entre as variáveis e seu objetivo é estimar os parâmetros dessa relação. Por outro lado, a regressão não paramétrica não assume uma forma funcional específica, permitindo maior flexibilidade na modelagem de dados complexos (Angelis; Sofos; Karakasidis, 2023).

2.2 ALGORITMOS GENÉTICOS

Algoritmos genéticos (AGs) são uma classe de algoritmos inspirados na evolução natural, onde soluções são evoluídas ao longo de gerações para resolver problemas complexos. Eles utilizam operações como seleção, cruzamento e mutação para explorar o espaço de soluções (Angelis; Sofos; Karakasidis, 2023; Kronberger; Burlacu *et al.*, 2024).


2.3 REGRESSÃO SIMBÓLICA

Regressão simbólica é uma técnica que busca encontrar expressões matemáticas que melhor descrevem a relação entre variáveis de entrada e saída em um conjunto de dados e pode ser categorizada como uma forma de regressão não paramétrica (Franca; Kronberger, 2025a,b). Algoritmos considerados *State of the Art* para regressão simbólica utilizam algoritmos genéticos para evoluir expressões matemáticas que representam essas relações (Olivetti de França, 2018; Kronberger; Burlacu *et al.*, 2024; Franca; Kronberger, 2025a). No entanto, a regressão simbólica também pode ser implementada usando outros métodos, como redes neurais e transformadores (Angelis; Sofos; Karakasidis, 2023).

2.3.1 PROGRAMAÇÃO GENÉTICA PARA REGRESSÃO SIMBÓLICA

A programação genética utilizada na regressão simbólica evolui expressões matemáticas representadas por árvores de sintaxe abstrata (ASTs). Cada nó da árvore representa uma operação matemática (adição, subtração, multiplicação, exponenciação, etc.) e as folhas representam variáveis de entrada ou constantes. A Figura 1 ilustra um exemplo de árvore de sintaxe abstrata para a expressão $\log(x/2) + 3x$.

Figura 1 – Exemplo de uma árvore de sintaxe abstrata (AST) para a expressão $\log(x/2) + 3x$.



Nós que representam operações matemáticas são representados por círculos, enquanto nós que representam variáveis de entrada ou constantes são representados por quadrados. Nós internos da árvore são chamados de não terminais, enquanto os nós folhas são chamados de terminais. O processo de busca envolve encontrar a melhor combinação de nós terminais e não terminais para minimizar a diferença entre os valores previstos pela expressão e os valores reais do conjunto de dados respeitando as restrições de complexidade e interpretabilidade da expressão (Angelis; Sofos; Karakasidis, 2023).

O processo de evolução se inicia com uma população inicial de expressões aleatórias. Em cada iteração, as expressões são avaliadas com base em uma função de aptidão, que mede o quão bem cada expressão se ajusta aos dados. As melhores expressões são selecionadas para reprodução, onde passam por operações de cruzamento e mutação para gerar novas expressões que são adicionadas à nova população. Esse processo continua até que um critério de parada seja atingido. Critérios de parada comuns incluem um número máximo de gerações, obtenção da expressão ideal ou convergência da população. Comumente, uma combinação entre todos os critérios é utilizada para garantir que o processo de evolução não seja interrompido prematuramente (Angelis; Sofos; Karakasidis, 2023; Kronberger; Burlacu *et al.*, 2024).

A Figura 2 ilustra o processo de cruzamento entre duas expressões. Na parte superior, os indivíduos pais e, na parte inferior, os indivíduos produzidos por eles. Durante esse processo, subárvores aleatórias são selecionadas em cada expressão e trocadas entre si para criar dois novos indivíduos. Note que o cruzamento pode resultar em expressões mais complexas que os pais originais, o que pode ser controlado por meio de restrições de profundidade ou tamanho da árvore.

A Figura 3 ilustra o processo de mutação, onde uma subárvore aleatória é selecionada e substituída por uma nova subárvore gerada aleatoriamente. A mutação introduz

Figura 2 – Exemplo de cruzamento entre duas expressões representadas por árvores de sintaxe abstrata (ASTs).





Figura 3 – Exemplo de mutação em uma expressão representada por uma árvore de sintaxe abstrata (AST).



diversidade na população, ajudando a evitar a convergência prematura para soluções subótimas. Na esquerda, o indivíduo original, e na direita, o indivíduo após a mutação.

É importante destacar que esse algoritmo não precisa necessariamente retornar uma única expressão. Um conjunto de expressões poder ser retornado, permitindo ao usuário escolher a que melhor se adequa às suas necessidades ([Angelis; Sofos; Karakasidis, 2023](#)).

Apesar dos avanços recentes, a regressão simbólica ainda enfrenta vários desafios. A complexidade computacional decorrente do grande espaço de busca de expressões possíveis pode tornar o processo de evolução lento e ineficiente. Além disso, a interpretabilidade das expressões geradas pode ser comprometida quando elas se tornam excessivamente complexas, dificultando a compreensão por parte dos usuários finais ([Angelis; Sofos; Karakasidis, 2023](#); [Kronberger; Burlacu et al., 2024](#)).

Além disso, a codificação de expressões como árvores pode levar o algoritmo de regressão a visitar expressões logicamente equivalentes várias vezes (Franca; Kronberger, 2025a). Por exemplo, as expressões $x + y$ e $y + x$ são logicamente iguais, mas seriam representadas por árvores diferentes. Testes empíricos indicam que apenas 40% das expressões geradas por algoritmos genéticos para regressão simbólica são únicas (Kronberger; Olivetti de Franca *et al.*, 2024).

2.4 SATURAÇÃO DE IGUALDADE PARA REGRESSÃO SIMBÓLICA


Diante dos desafios enfrentados pela regressão simbólica tradicional, uma abordagem alternativa que tem ganhado destaque é o uso de grafos de igualdade (Equality Graphs - e-graphs) para representar e manipular expressões matemáticas (Franca; Kronberger, 2025a,b). E-graphs são estruturas de dados que armazenam múltiplas expressões equivalentes de forma compacta, permitindo a aplicação eficiente de transformações algébricas e simplificações nos indivíduos presentes no espaço de busca. Utilizando essa estrutura de dados, é possível realizar uma operação chamada de saturação de igualdade, que consiste em aplicar regras de reescrita para gerar todas as expressões logicamente equivalentes a uma dada expressão inicial.

2.4.1 GRAFOS DE IGUALDADE

Grafos de igualdade são estruturas de dados que representam expressões matemáticas e suas equivalências de maneira eficiente. Elementos matemáticos são representados por e-nodes, enquanto classes de expressões equivalentes são representadas por e-classes. Cada e-class contém um conjunto de e-nodes que representam diferentes formas de expressar a mesma expressão matemática. Cada e-node aponta para e-classes filhas, que representam os operandos da operação matemática representada pelo e-node.

A Figura 4 ilustra um grafo de igualdade. Note que as expressões $2x$ e $x + x$ pertencem à mesma e-class, uma vez que são logicamente equivalentes. A implementação de e-graphs utiliza uma estrutura union-find para gerenciar a união de e-classes quando novas equivalências são descobertas durante o processo de saturação (Franca; Kronberger, 2025a). Uma e-class armazena uma lista de e-nodes que pertencem a ela, uma lista de e-nodes pais (e-nodes que possuem essa e-class como filha) e demais informações auxiliares para otimizar operações de busca e união.

Figura 4 – Exemplo de um grafo de igualdade, adaptado de (Franca; Kronberger, 2025a).



REFERÊNCIAS

ANGELIS, Dimitrios; SOFOS, Filippos; KARAKASIDIS, Theodoros E. Artificial Intelligence in Physical Sciences: Symbolic Regression Trends and Perspectives. **Archives of Computational Methods in Engineering**, v. 30, n. 6, p. 3845–3865, jul. 2023. ISSN 1886-1784. DOI: [10.1007/s11831-023-09922-z](https://doi.org/10.1007/s11831-023-09922-z). Disponível em: <https://doi.org/10.1007/s11831-023-09922-z>.

FRANCA, Fabricio Olivetti de; KRONBERGER, Gabriel. Improving Genetic Programming for Symbolic Regression with Equality Graphs. *In: PROCEEDINGS of the Genetic and Evolutionary Computation Conference*. Malaga, Spain: Association for Computing Machinery, 2025. (GECCO '25). ISBN 9798400714658. DOI: [10.1145/3712256.3726383](https://doi.org/10.1145/3712256.3726383). arXiv: [2501.17848](https://arxiv.org/abs/2501.17848) [cs.LG]. Disponível em: <https://doi.org/10.1145/3712256.3726383>.

FRANCA, Fabricio Olivetti de; KRONBERGER, Gabriel. rEGGression: an Interactive and Agnostic Tool for the Exploration of Symbolic Regression Models. *In: PROCEEDINGS of the Genetic and Evolutionary Computation Conference*. Malaga, Spain: Association for Computing Machinery, 2025. (GECCO '25). ISBN 9798400714658. DOI: [10.1145/3712256.3726385](https://doi.org/10.1145/3712256.3726385). arXiv: [2501.17859](https://arxiv.org/abs/2501.17859) [cs.LG]. Disponível em: <https://doi.org/10.1145/3712256.3726385>.

KRONBERGER, Gabriel; BURLACU, Bogdan *et al.* **Symbolic Regression**. [S. l.: s. n.], jul. 2024. ISBN 9781315166407. DOI: [10.1201/9781315166407](https://doi.org/10.1201/9781315166407).

KRONBERGER, Gabriel; OLIVETTI DE FRANCA, Fabricio *et al.* The Inefficiency of Genetic Programming for Symbolic Regression. *In: AFFENZELLER, Michael et al. (ed.). Parallel Problem Solving from Nature – PPSN XVIII*. Cham: Springer Nature Switzerland, 2024. p. 273–289. ISBN 978-3-031-70055-2.

OLIVETTI DE FRANÇA, Fabrício. A greedy search tree heuristic for symbolic regression. **Information Sciences**, Elsevier BV, 442–443, p. 18–32, maio 2018. ISSN 0020-0255. DOI: [10.1016/j.ins.2018.02.040](https://doi.org/10.1016/j.ins.2018.02.040). Disponível em: <http://dx.doi.org/10.1016/j.ins.2018.02.040>.

STULP, Freek; SIGAUD, Olivier. Many regression algorithms, one unified model: A review. **Neural Networks**, v. 69, p. 60–79, 2015. ISSN 0893-6080. DOI: <https://doi.org/10.1016/j.neunet.2015.05.005>. Disponível em: <https://www.sciencedirect.com/science/article/pii/S0893608015001185>.